Δομές Δεδομένων και Αλγόριθμοι

Ονοματεπώνυμο: Ερμιόνη Φώτη

Α.Μ.: 2020030081

Ημερομηνία : 12/06/2023

Άσκηση 3: Αναζήτηση σε Αρχεία κειμένου με χρήση Δεικτοδότησης (indexing)

Σύντομη Περιγραφή Κώδικα

Κλάσεις και Μέθοδοι

Η υλοποίηση του BPlusTree είναι έτοιμη από το Web και συγκεκριμένα από τον παρακάτω σύνδεσμο https://github.com/linli2016/BPlusTree . Ωστόσο, για τις ανάγκες τις συγκεκριμένης άσκησης, πραγματοποιήθηκαν κάποιες αλλαγές στην κλάση BPlusTreeLeafNode κυρίως στην μέθοδο insertAt(). Ουσιαστικά, μετά την διαφοροποίηση η insertAt() μπορεί να χειριστεί τα διπλότυπα κλειδιά αποθηκεύοντας πολλές τιμές για το ίδιο κλειδί.

Παρακάτω παρουσιάζονται οι επιπλέον κλάσεις που υλοποιήθηκαν.

- ***Token, TokenIterator***

  Η κλάση Token περιέχει ένα (String) token ,που αναπαριστά την λέξη του αρχείου και ένα (int) position, που αναπαριστά τη θέση της στο αρχείο. Η κλάση TokenIterator υλοποιεί τη διεπαφή Iterator<Token> και χρησιμοποιείται για την ανάγνωση των Token από το αρχείο. Με την μέθοδο next() επιστρέφεται κάθε φορά το τρέχον Token και ενημερώνονται οι αντίστοιχες μεταβλητές, καθώς και ο δείκτης θέσης.

- ***PositionInFile***

  Η κλάση αυτή χρησιμοποιείται για να αποθηκεύσει πληροφορίες για το όνομα ενός αρχείου και τη θέση στην οποία βρίσκεται μία λέξη .

- ***SearchStats***

  Η κλάση αυτή χρησιμοποιείται για την καταγραφή στατιστικών πληροφοριών κατά την διαδικασία της αναζήτησης. Συγκεκριμένα, περιέχει μία μεταβλητή που αναπαριστά το πλήθος κόμβων του B+ Tree που έκανε προσπέλαση (nodeAccessCount) και μία μεταβλητή που αναπαριστά τον αριθμό συγκρίσεων που έγιναν με κλειδιά στο δέντρο.

- ***Main***

  Η κλάση αυτή περιέχει ένα μενού και ανάλογα με την επιλογή του χρήστη εκτελεί κάθε φορά μία από της ζητηθέντες λειτουργίες. Η επιλογή 1 εισάγει την πληροφορία των λέξεων ενός αρχείου στο B+Tree . Συγκεκριμένα, ο χρήστης εισάγει το όνομα του αρχείου και στην συνέχεια το πρόγραμμα δημιουργεί ένα αντικείμενο TokenIterator για να διαχειριστεί τις λέξεις (tokens) του αρχείου. Με τη χρήση της επανάληψης κάθε λέξη

του αρχείου (Token.token) αποθηκεύεται ως κλειδί(key) στο δέντρο , ενώ κάθε αντικείμενο PositionInFile που αντιστοιχεί στη θέση της λέξης αποθηκεύεται ως τιμή (value) στο δέντρο. Η επιλογή 2 ρωτάει για μία λέξη προς αναζήτηση και τυπώνει την πληροφορία που υπάρχει για αυτήν, το πλήθος των κόμβων που έκανε προσπέλαση, καθώς και τον αριθμό των συγκρίσεων που έγιναν με τα κλειδιά του δέντρου. Συγκεκριμένα, ο χρήστης εισάγει μία λέξη προς αναζήτηση και στη συνέχεια με τη χρήση της search αναζητείται η λέξη στο δέντρο και επιστρέφεται μία λίστα από αντικείμενα PositionInFile ,που αντιπροσωπεύουν τις θέσεις που βρίσκεται η λέξη στα αρχεία που έχουν εισαχθεί παραπάνω, καθώς και τα στατιστικά που προέκυψαν από την συγκεκριμένη αναζήτηση. Τέλος, η επιλογή 3 εισάγει τα 2 αρχεία που μας δόθηκαν σε ένα καινούργιο δέντρο, επιλέγει τυχαία 50 λέξεις από κάθε δέντρο και πραγματοποιεί αναζήτηση σε αυτές με σκοπό τον υπολογισμό του μέσου αριθμού προσβάσεων κόμβων , καθώς και του μέσου αριθμού συγκρίσεων με κλειδιά. Η διαδικασία αυτή επαναλαμβάνεται για τάξη M= 10 και για τάξη M = 20. Για τις ανάγκες αυτού του ερωτήματος, έγινε χρήση της μεθόδου readWordsFromFile , η οποία επιστρέφει μία λίστα από τις λέξεις που περιέχονται στο κάθε αρχείο και της μεθόδου getRandomWords, που επιλέγει τυχαία έναν συγκεκριμένο αριθμό λέξεων από την παραπάνω λίστα.

Καταγραφή Αποτελεσμάτων

Α1.Μέσος Αριθμός προσβάσεων κόμβων στο Ευρετήριο (B+-tree) για αναζήτηση Τάξη M = 10	Α.2 Μέσος Αριθμός συγκρίσεων με κλειδιά για αναζήτηση Τάξη M = 10	Α1.Μέσος Αριθμός προσβάσεων κόμβων στο Ευρετήριο (B+-tree) για αναζήτηση Τάξη M = 20	Α.2 Μέσος Αριθμός συγκρίσεων με κλειδιά για αναζήτηση Τάξη M = 20
4.0	16.0	4.0	20.0

Σχολιασμός Αποτελεσμάτων

1. Όσον αφορά τον μέσο αριθμό προσβάσεων για αναζήτηση, σε ένα B+Tree είναι ίσος με το ύψος του δέντρου. Αυτό συμβαίνει, καθώς τα κλειδιά αποθηκεύονται μόνο στους κόμβους φύλλα οπότε για την αναζήτηση ενός κλειδιού απαιτείται να γίνει κάθε φορά διάσχιση όλου του δέντρου. Θεωρητικά , το ύψος του δέντρου υπολογίζεται από τον τύπο h $\simeq log_n N$, όπου n η τάξη του δέντρου και N ο αριθμός των κλειδιών που περιλαμβάνει το δέντρο. Στην συγκεκριμένη άσκηση, ο συνολικός αριθμός κλειδιών ισούται με 3908 οπότε για τάξη M= 10 το θεωρητικό αποτέλεσμα που προκύπτει είναι ίσο με 3,59,δηλαδή 4 ενώ για τάξη M = 20 είναι ίσο με 2,76 , δηλαδή 3. Συγκρίνοντας τις θεωρητικές με τις πειραματικές μετρήσεις βλέπουμε ότι παρουσιάζεται μία μικρή απόκλιση στον μέσο αριθμό προσβάσεων για τάξη M = 20, δηλαδή αντί για 3 υπολογίζεται 4. Αυτή η απόκλιση μπορεί να οφείλεται στο γεγονός ότι μπορεί ορισμένοι κόμβοι να μην περιέχουν το μέγιστο αριθμό κλειδιών που είναι 20, αλλά λιγότερα.

2. Στην περίπτωση που το B+Tree και το Ευρετήριο βρίσκονταν στο δίσκο, η αξιολόγηση των αποτελεσμάτων επικεντρώνεται κυρίως στον αριθμό των προσβάσεων στο δίσκο που απαιτούνται για την πρόσβαση στα δεδομένα. Το B+Tree θεωρείται κατάλληλο για αποθήκευση σε δίσκο, καθώς ελαχιστοποιεί τις προσβάσεις στο δίσκο. Συγκεκριμένα, κάθε κόμβος αντιστοιχεί σε μία σελίδα δίσκου και κάθε πρόσβαση σε έναν κόμβο απαιτεί μία ανάγνωση από τον δίσκο. Συνεπώς, καθώς το B+Tree σχεδιάστηκε έτσι ώστε να διατηρεί μικρό ύψος για μεγάλο αριθμό δεδομένων, ο αριθμός των προσβάσεων στο δίσκο είναι πολύ μικρός ακόμα και για αναζητήσεις μεγάλου όγκου δεδομένων .